Procesamiento en Batch

• Realizar el cargue del dataset en la herramienta Hadoop.

Requisitos previos: Tener instalado spark en Ubuntu

Iniciamos una sesión por putty e ingresamos con el usuario:

Usuario: hadoop Password: hadoop

Iniciamos el clúster de Hadoop con el siguiente comando:

start-all.sh

```
who hadoop@bigdata: ~ $ su - hadoop

Password:
hadoop@bigdata: ~ $ start-all.sh

WARNING: Attempting to start all Apache Hadoop daemons as hadoop in 10 seconds.

WARNING: This is not a recommended production deployment configuration.

WARNING: Use CTRL-C to abort.

Starting namenodes on [localhost]

Starting datanodes

Starting secondary namenodes [bigdata]

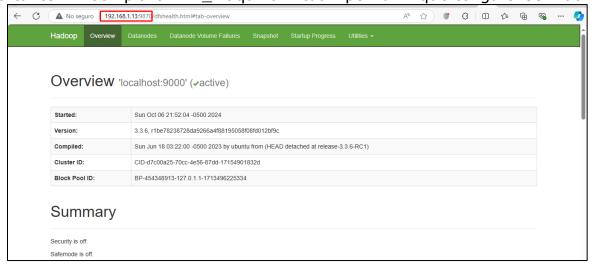
Starting resourcemanager

Starting nodemanagers

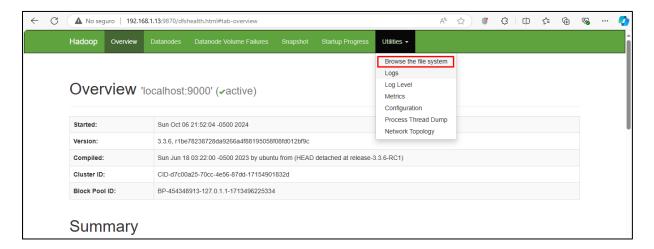
hadoop@bigdata: ~ $
```

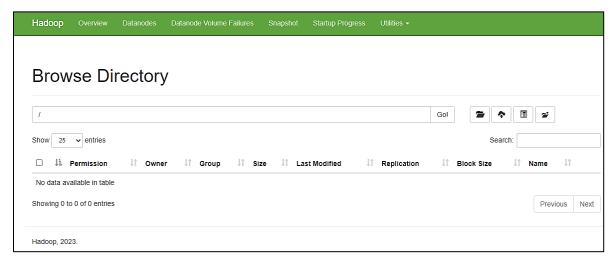
Una vez iniciados todos los servicios, puede acceder al Hadoop en: http://IP MaquinaVirtual:9870

Importante: *Reemplazar "IP_MaquinaVirtual" por la IP que tenga el servidor*



Puede visualizar el sistema de archivos HDFS en la opción Utilities-Browse the file system





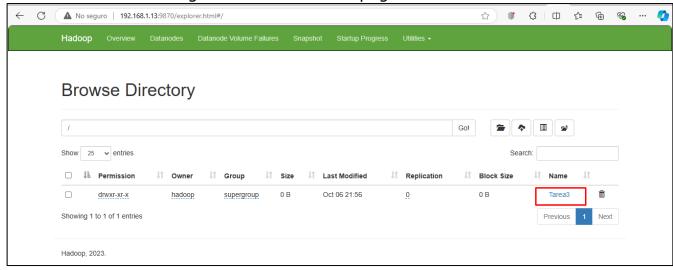
Ahora se crea una carpeta en el sistema HDFS utilizando el comando:

hdfs dfs -mkdir /Tarea3

con esto creamos una carpeta llamada Tarea3 en el sistema HDFS:

```
🧬 hadoop@bigdata: ~
                                                                          ×
vboxuser@bigdata:~$ su - hadoop
Password:
hadoop@bigdata:~$ start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as hadoop in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [bigdata]
Starting resourcemanager
Starting nodemanagers
hadoop@bigdata:~$ hdfs dfs -mkdir /Tarea3
hadoop@bigdata:~$
```

Verificamos en el navegador refrescando la página:



Con la siguiente dirección WEB y usando el comando wget, descargamos el dataset que utilizaremos para el ejercicio:

https://www.datos.gov.co/api/views/g4vd-w4ip/rows.csv

Comando:

wget https://www.datos.gov.co/api/views/mcec-87by/rows.csv

Ejemplo:

```
🙀 hadoop@bigdata: ~
                                                                         X
hadoop@bigdata:~$ start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as hadoop in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [bigdata]
Starting resourcemanager
Starting nodemanagers
hadoop@bigdata:~$ hdfs dfs -mkdir /Tarea3
hadoop@bigdata:~$ wget https://www.datos.gov.co/api/views/mcec-87by/rows.csv
--2024-10-07 03:02:12-- https://www.datos.gov.co/api/views/mcec-87by/rows.csv
Resolving www.datos.gov.co (www.datos.gov.co)... 52.206.68.26, 52.206.140.205, 5
2.206.140.199
Connecting to www.datos.gov.co (www.datos.gov.co)|52.206.68.26|:443... connected
HTTP request sent, awaiting response... 200 OK
Length: unspecified [text/csv]
Saving to: 'rows.csv'
                        [ <=>
                                             ] 262,57K
                                                        911KB/s
                                                                    in 0,3s
rows.csv
2024-10-07 03:02:13 (911 KB/s) - 'rows.csv' saved [268868]
hadoop@bigdata:~$
```

Ahora copiamos el archivo del Dataset descargado a la carpeta HDFS que creamos anteriormente con el siguiente comando:

hdfs dfs -put /home/hadoop/rows.csv /Tarea3

```
🗬 hadoop@bigdata: ~
                                                                         X
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datamodes
Starting secondary namenodes [bigdata]
Starting resourcemanager
Starting nodemanagers
hadoop@bigdata:~$ hdfs dfs -mkdir /Tarea3
hadoop@bigdata:~$ wget https://www.datos.gov.co/api/views/mcec-87by/rows.csv
--2024-10-07 03:02:12-- https://www.datos.gov.co/api/views/mcec-87by/rows.csv
Resolving www.datos.gov.co (www.datos.gov.co)... 52.206.68.26, 52.206.140.205,
2.206.140.199
Connecting to www.datos.gov.co (www.datos.gov.co)|52.206.68.26|:443... connected
HTTP request sent, awaiting response... 200 OK
Length: unspecified [text/csv]
Saving to: 'rows.csv'
                        [ <=>
rows.csv
                                             ] 262,57K 911KB/s
                                                                    in 0,3s
2024-10-07 03:02:13 (911 KB/s) - 'rows.csv' saved [268868]
hadoop@bigdata:~$ pwd
/home/hadoop
hadoop@bigdata:~$ hdfs dfs -put /home/hadoop/rows.csv /Tarea3
hadoop@bigdata:~$
```

Con el siguiente comando podemos ver el archivo del dataset en la carpeta HDFS llamada Tarea 3:

hdfs dfs -ls /Tarea3

```
🧬 hadoop@bigdata: ~
                                                                         ×
Starting secondary namenodes [bigdata]
Starting resourcemanager
Starting nodemanagers
hadoop@bigdata:~$ hdfs dfs -mkdir /Tarea3
hadoop@bigdata:~$ wget https://www.datos.gov.co/api/views/mcec-87by/rows.csv
--2024-10-07 03:02:12-- https://www.datos.gov.co/api/views/mcec-87by/rows.csv
Resolving www.datos.gov.co (www.datos.gov.co)... 52.206.68.26, 52.206.140.205,
2.206.140.199
Connecting to www.datos.gov.co (www.datos.gov.co)|52.206.68.26|:443... connected
HTTP request sent, awaiting response... 200 OK
Length: unspecified [text/csv]
Saving to: 'rows.csv'
                        [ <=>
                                            ] 262,57K 911KB/s
rows.csv
                                                                    in 0,3s
2024-10-07 03:02:13 (911 KB/s) - 'rows.csv' saved [268868]
hadoop@bigdata:~$ pwd
/home/hadoop
hadoop@bigdata:~$ hdfs dfs -put /home/hadoop/rows.csv /Tarea3
hadoop@bigdata:~$ hdfs dfs -ls /Tarea3
Found 1 items
-rw-r--r-- l hadoop supergroup
                                    268868 2024-10-07 03:04 /Tarea3/rows.csv
hadoop@bigdata:~$
```

NOTA: En este punto queda cargado el dataset en el sistema de archivos HDFS, esto es muy importante para ejecutar el código.

Ejecución del código

Ejecutamos una nueva sesión por putty sin cerrar la que ya está establecida e ingresamos con el usuario:

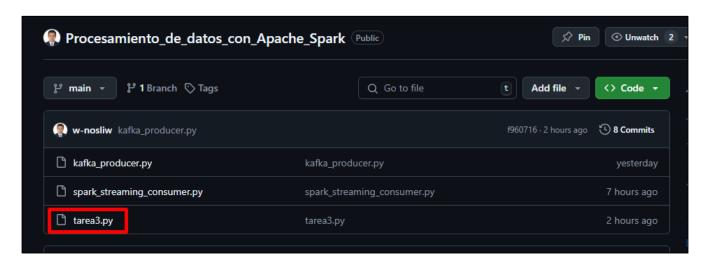
Usuario: vboxuser Contraseña: bigdata

Se crea un archivo de python con extension .py llamado tarea3.py, donde colocaremos el código del programa que se conectará al dataset descargado dentro del sistema HDFS, luego convertiremos estos datos en un dataframe de Spark y sobre este dataframe se realizarán diferentes operaciones y consultas. Para crea este archivo se ejecuta el siguiente comando:

nano tarea3.py



Pegamos el código que se encuentra en este repositorio de GitHub con el nombre tarea3.py:



- # Importamos librerías necesarias from pyspark.sql import SparkSession, functions as F
- # Inicializa la sesión de Spark spark = SparkSession.builder.appName('Tarea3').getOrCreate()

```
# Define la ruta del archivo CSV
file path = 'hdfs://localhost:9000/Tarea3/rows.csv'
# Lee el archivo CSV
df = spark.read.format('csv').option('header',
'true').option('inferSchema', 'true').load(file path)
# Muestra el esquema del DataFrame
df.printSchema()
# Limpiar duplicados y eliminar valores nulos en columnas clave
df_clean = df.dropDuplicates().na.drop(subset=["EDAD", "SEXO", "TIPO
DE VEHÍCULO", "COSTOS", "FECHA DE ACCIDENTE"])
# ------ Análisis Exploratorio de Datos (EDA) ------
# 1. Estadísticas básicas del conjunto de datos
print("Resumen de estadísticas del conjunto de datos:")
df clean.summary().show()
# 2. Accidentes por tipo de vehículo
accidentes por vehiculo = df clean.groupBy("TIPO DE
VEHÍCULO").count().orderBy(F.col("count").desc())
print("Accidentes por tipo de vehículo:")
accidentes por vehiculo.show()
# 3. Distribución de accidentes por día de la semana
accidentes_por_dia = df_clean.groupBy("DIA
SEMANA").count().orderBy(F.col("count").desc())
print("Distribución de accidentes por día de la semana:")
accidentes_por_dia.show()
# 4. Estadísticas de edad según el tipo de vehículo
edad_por_vehiculo = df_clean.groupBy("TIPO DE VEHÍCULO").agg(
  F.mean("EDAD").alias("Edad Promedio"),
  F.min("EDAD").alias("Edad Mínima"),
  F.max("EDAD").alias("Edad Máxima")
)
print("Estadísticas de edad por tipo de vehículo:")
edad_por_vehiculo.show()
# 5. Filtrado: Accidentes donde el usuario es conductor
accidentes_conductor = df_clean.filter(F.col("RELACION
USUARIO/ACCIDENTE") == "CONDUCTOR")
print("Accidentes donde el usuario es conductor:")
accidentes_conductor.show(5)
```

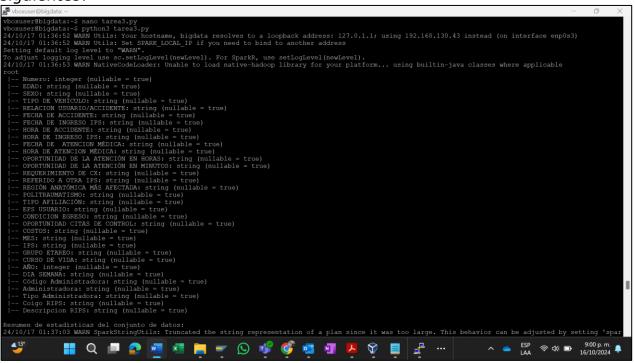
```
# 6. Accidentes por grupo etario
accidentes_por_grupo_etario = df_clean.groupBy("GRUPO
ETAREO").count().orderBy(F.col("count").desc())
print("Accidentes por grupo etario:")
accidentes por grupo etario.show()
# 7. Promedio de tiempo de atención (en horas) en accidentes
promedio atencion horas = df clean.groupBy("TIPO DE
VEHÍCULO").agg(
  F.mean("OPORTUNIDAD DE LA ATENCIÓN EN HORAS").alias("Tiempo
Promedio Atención (Horas)")
print("Promedio de tiempo de atención en horas según tipo de
vehículo:")
promedio_atencion_horas.show()
# 8. Accidentes filtrados por altos costos de atención médica
accidentes costos altos = df clean.filter(F.col("COSTOS") >
100000).select("NUMERO", "COSTOS", "TIPO DE VEHÍCULO", "SEXO")
print("Accidentes con costos mayores a 100,000:")
accidentes costos altos.show()
# 9. Número de accidentes por mes
accidentes por mes =
df clean.groupBy("MES").count().orderBy(F.col("count").desc())
print("Número de accidentes por mes:")
accidentes_por_mes.show()
# 10. Porcentaje de accidentes por sexo
accidentes por sexo =
df_clean.groupBy("SEXO").count().withColumn("Porcentaje",
(F.col("count") / df clean.count()) * 100)
print("Porcentaje de accidentes por sexo:")
accidentes_por_sexo.show()
# Detener la sesión de Spark
spark.stop()
Una vez pegado el código oprimir Crtl+O - enter y finalmente Crtl+X para salir
del archivo.
Ejecutar el archivo con el siguiente comando:
python3 tarea3.py
```

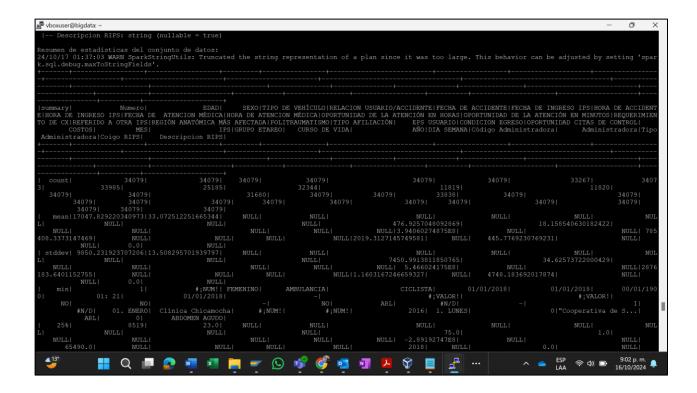
```
vboxuser@bigdata:~

vboxuser@bigdata:~

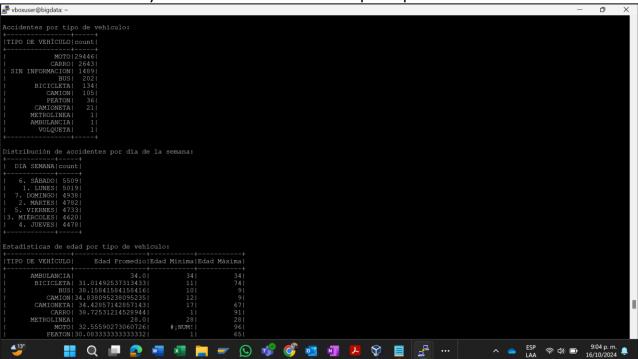
python3 tarea3.py
24/10/07 03:23:27 WARN Utils: Your hostname, bigdata resolves to a loopback addr
ess: 127.0.1.1; using 192.168.1.13 instead (on interface enp0s3)
24/10/07 03:23:27 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another
address
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
24/10/07 03:23:29 WARN NativeCodeLoader: Unable to load native-hadoop library for
r your platform... using builtin-java classes where applicable
```

Al terminar la ejecución del archivo debemos obtener resultados similares a los siguientes:

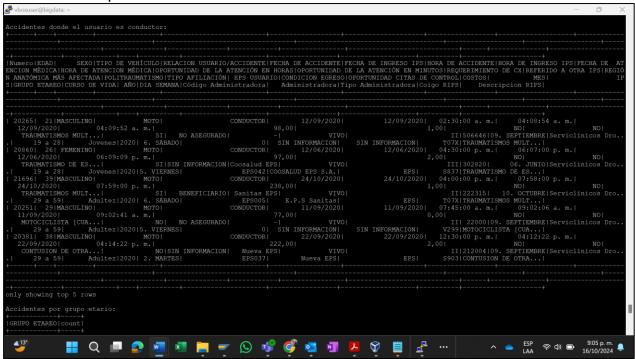




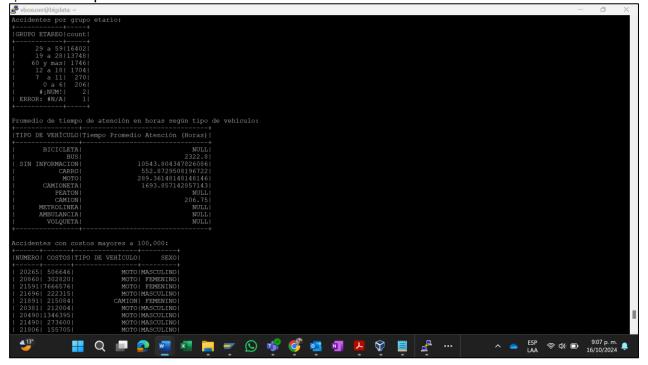
Visualizamos los accidentes por tipo de vehículo, la distribución de accidentes por día de la semana y las estadísticas de edad por tipo de vehículo



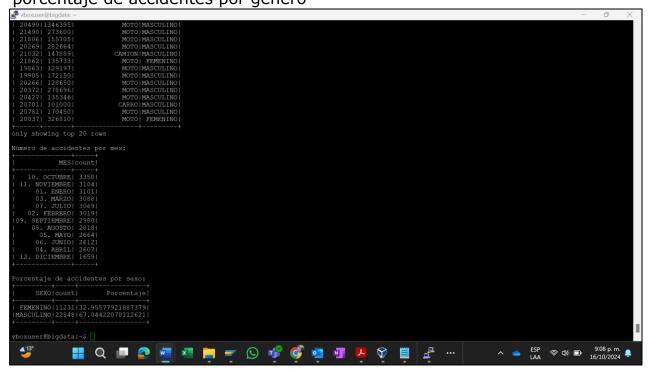
Vemos un reporte de accidentes donde el usuario es el conductor



Visualizamos un reporte de accidentes por grupo etario, el promedio de tiempo de atención en horas según tipo de vehículo y los accidentes con costos mayores a \$100.000 pesos



Finalmente visualizamos un reporte del número de accidentes por mes y el porcentaje de accidentes por genero



Procesamiento en tiempo real (Spark Streaming & Kafka):

Requisitos previos: Tener instalado Spark y Kafka en ubuntu

Ejecutamos una sesión por putty e ingresamos con el usuario:

Usuario: vboxuser Contraseña: bigdata

Creamos un tema (topic) de Kafka, el tema se llamará sensor_data con el siguiente comando:

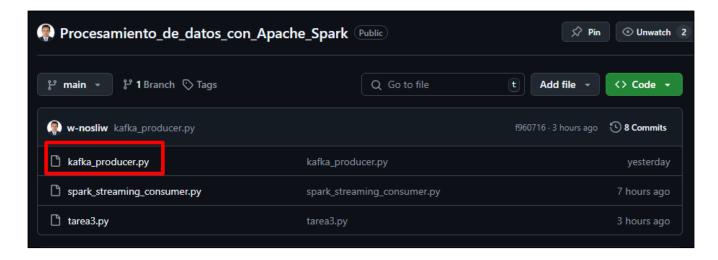
/opt/Kafka/bin/kafka-topics.sh --create --bootstrap-server localhost:9092 -- replication-factor 1 --partitions 1 --topic sensor_data

```
vboxuser@bigdata: ~
                                                                                     ×
vboxuser@bigdata:~$ /opt/Kafka/bin/kafka-topics.sh --create --bootstrap-server localho
st:9092 --replication-factor l --partitions l --topic sensor data
WARNING: Due to limitations in metric names, topics with a period ('.') or underscore
(' ') could collide. To avoid issues it is best to use either, but not both.
[2024-10-15 00:46:51,087] INFO Creating topic sensor data with configuration {} and in
itial partition assignment HashMap(0 -> ArrayBuffer(0)) (kafka.zk.AdminZkClient)
[2024-10-15 00:46:51,310] INFO [Controller id=0, targetBrokerId=0] Node 0 disconnected
 (org.apache.kafka.clients.NetworkClient)
[2024-10-15 00:46:51,388] INFO [ReplicaFetcherManager on broker 0] Removed fetcher for
partitions Set(sensor data-0) (kafka.server.ReplicaFetcherManager)
[2024-10-15 00:46:51,525] INFO [LogLoader partition=sensor data-0, dir=/tmp/kafka-logs
] Loading producer state till offset 0 with message format version 2 (kafka.log.Unifie
dLog$)
[2024-10-15 00:46:51,595] INFO Created log for partition sensor data-0 in /tmp/kafka-1
ogs/sensor data-0 with properties {} (kafka.log.LogManager)
[2024-10-15 00:46:51,601] INFO [Partition sensor data-0 broker=0] No checkpointed high
watermark is found for partition sensor data-0 (kafka.cluster.Partition)
[2024-10-15 00:46:51,604] INFO [Partition sensor data-0 broker=0] Log loaded for parti
tion sensor data-0 with initial high watermark 0 (kafka.cluster.Partition)
Created topic sensor data.
vboxuser@bigdata:~$
```

Creamos un archivo llamado kafka_producer.py con el siguiente comando:

nano kafka_producer.py

Pegamos el código que se encuentra en este repositorio de GitHub con el nombre kafka_producer.py:



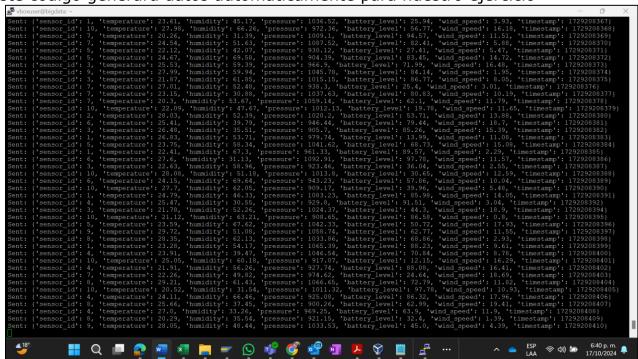
```
import time
import json
import random
from kafka import KafkaProducer
def generate_sensor_data():
  return {
    "sensor_id": random.randint(1, 10),
    "temperature": round(random.uniform(20, 30), 2),
    "humidity": round(random.uniform(30, 70), 2),
    "pressure": round(random.uniform(900, 1100), 2), # Presión en
hPa
    "battery_level": round(random.uniform(10, 100), 2), # Nivel de
batería en %
    "wind_speed": round(random.uniform(0, 20), 2), # Velocidad del
viento en m/s
    "timestamp": int(time.time())
  }
producer = KafkaProducer(bootstrap_servers=['localhost:9092'],
              value serializer=lambda x: json.dumps(x).encode('utf-
8'))
while True:
  sensor_data = generate_sensor_data()
  producer.send('sensor_data', value=sensor_data)
  print(f"Sent: {sensor_data}")
  time.sleep(1)
```

Una vez pegado el código oprimir Crtl+O - enter y finalmente Crtl+X para salir del archivo.

Ejecutar el archivo con el siguiente comando:

python3 kafka producer.py

Este código generará datos automáticamente para nuestro ejercicio



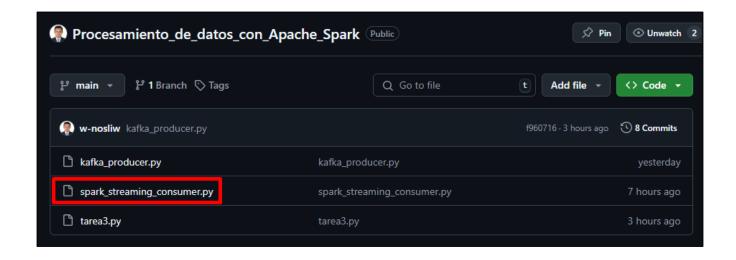
Ejecutamos una nueva sesión por putty sin cerrar la actual donde se está ejecutando el archivo producer e ingresamos con el usuario:

Usuario: vboxuser Contraseña: bigdata

Ahora, crearemos un consumidor(consumer) utilizando Spark Streaming para procesar los datos en tiempo real. Crea un archivo llamado spark_streaming_consumer.py con el siguiente comando:

nano spark_streaming_consumer.py

Pegamos el código que se encuentra en este repositorio de GitHub con el nombre spark_streaming_consumer.py:



```
from pyspark.sql import SparkSession
from pyspark.sql.functions import from_json, col, window
from pyspark.sql.types import StructType, StructField, IntegerType,
FloatType, TimestampType
# Configura el nivel de log a WARN para reducir los mensajes INFO
spark=SparkSession.builder\
 .appName("KafkaSparkStreaming")\
 .getOrCreate()
spark.sparkContext.setLogLevel("WARN")
# Definir el esquema para los datos de entrada
schema = StructType([
  StructField("sensor_id", IntegerType()),
  StructField("temperature", FloatType()),
  StructField("humidity", FloatType()),
  StructField("pressure", FloatType()),
                                           # Nuevo campo de presión
  StructField("battery_level", FloatType()),
                                             # Nuevo campo de nivel de
batería
  StructField("wind_speed", FloatType()),
                                             # Nuevo campo de
velocidad del viento
  StructField("timestamp", TimestampType())
])
# Crear una sesión de Spark
spark = SparkSession.builder\
  .appName("SensorDataAnalysis")\
  .getOrCreate()
# Configurar el lector de streaming para leer desde Kafka
df = spark\
```

```
.readStream\
  .format("kafka")\
  .option("kafka.bootstrap.servers", "localhost:9092")\
  .option("subscribe", "sensor_data")\
  .load()
# Parsear los datos JSON
parsed df = df.select(from json(col("value").cast("string"),
schema).alias("data")).select("data.*")
# Calcular estadísticas por ventana de tiempo (promedios por sensor y
por minuto)
windowed stats=parsed df\
  .groupBy(window(col("timestamp"), "1 minute"), "sensor_id")\
  .agg({
    "temperature": "avg",
    "humidity":"avg",
    "pressure":"avg",
    "battery_level":"avg",
    "wind speed":"avg"
  })
# Escribir los resultados en la consola
query=windowed stats\
  .writeStream\
  .outputMode("complete")\
  .format("console")\
  .start()
```

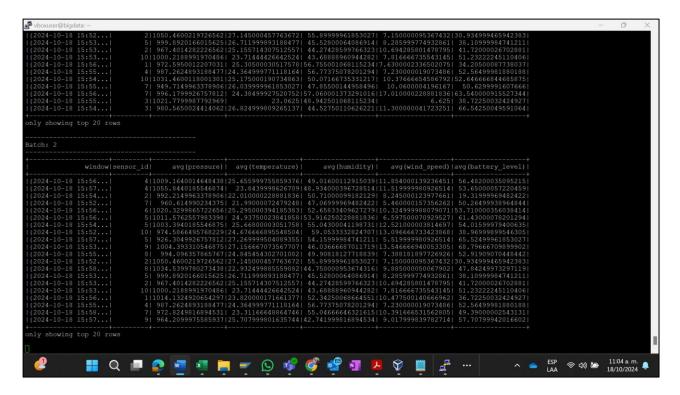
query.awaitTermination()

Una vez pegado el código oprimir Crtl+O - enter y finalmente Crtl+X para salir del archivo.

Ejecutar el archivo con el siguiente comando:

```
spark-submit --packages org.apache.spark:spark-sql-kafka-0-10 2.12:3.5.3
spark_streaming_consumer.py
```

Una vez ejecutado el código, empezará a recibir los datos proporcionados por el producer, los analiza y finalmente nos muestra los datos procesados el lotes de tiempo:



Podemos observar ambos códigos trabajando al mismo tiempo: el generador y el consumidor:

